

## Índice

- 4.3.1 Breve introducción al álgebra relacional
- 4.3.2 Objetivo
- 4.3.3 Visión general
- 4.3.4 Optimización heurística
- 4.3.5 Estimación del coste
- 4.3.6 Optimización de consultas en Oracle
- 4.3.7 Ejercicios

## Bibliografía

- Fundamentals of Database Systems. 6<sup>th</sup> Edition  
R. Elmasri y S.B. Navathe. Addison Wesley, 2010  
Capítulo 18
- Database: Principles, Programming, and Performance, 2<sup>a</sup> Edición  
P. O'Neil y E. O'Neil. Morgan Kaufmann, 2000  
Capítulo 9
- Fundamentos de bases de datos. 5<sup>a</sup> edición  
A. Silberschatz, H.F. Korth y S. Sudarshan. McGraw-Hill, 2006  
Capítulos 15 y 17
- Oracle 10g: Manual del administrador  
K. Loney. McGraw-Hill, 2005  
Capítulo 7



## 4.3.1 Álgebra relacional

- Los lenguajes relacionales son lenguajes formales (teórico-matemáticos) y se basan en el carácter conjuntista de una relación.
- El álgebra relacional es un lenguaje procedimental para la manipulación de relaciones.
- El Álgebra relacional fue desarrollada en 1970 y el cálculo relacional en 1971 por Codd.
- El Álgebra y el Cálculo Relacional proveen una forma teórica de manipular una base de datos relacional.
- Se basa en el álgebra de la teoría de conjuntos donde los operandos son tablas o relaciones.
- Manipula relaciones produciendo nuevas relaciones.
- Cualquier operación da como resultado una tabla o relación con la que se puede operar de nuevo.
- Consiste en operaciones que algunas de ellas son tomadas de la matemática, otras del lenguaje relacional y otras de lenguajes de programación comunes.
- La cláusula SELECT de SQL es en buena medida una implementación del álgebra relacional.



### 4.3.1 Álgebra relacional: operaciones

- Básicas
  - Unarias: operan con una sola tabla.
    - Selección
    - Proyección
  - Binarias o de conjunto: Operan con dos tablas.
    - Unión
    - Diferencia
    - Producto cartesiano
- Derivadas o adicionales: realizan en su proceso llamadas a las operaciones básicas.
  - Intersección
  - Cociente o división
  - Join o reunión



### 4.3.1 Álgebra relacional: operaciones

- De conjuntos:
  - Unión
  - Intersección
  - Diferencia de conjuntos
  - Producto Cartesiano
- De programación:
  - Asignación
- Relacionales:
  - Proyección
  - Selección
  - División o cociente
  - Join



### 4.3.1 Álgebra relacional: tablas de ejemplo

R			S		T			Q			V
A	B	C	B	D	A	B	C	B	D	E	E
1	0	1	0	3	1	1	0	2	1	0	0
1	0	0	3	0	1	0	1	1	1	1	3
0	3	2	2	1	1	2	1	2	1	3	
1	2	3			2	0	0	0	3	0	
0	2	0			1	2	3	3	0	0	



### 4.3.1 Álgebra relacional: selección

Notación:  $\sigma_c(R)$

Ejemplo:

Tresul:=  $\sigma_{(C>1 \text{ AND } B>2)}(R)$

R			Tresul		
A	B	C	A	B	C
1	0	1			
1	0	0			
0	3	2	0	3	2
1	2	3			
0	2	0			



### 4.3.1 Álgebra relacional: proyección

Notación:  $\pi_{a_1, a_2, \dots}(R)$

Ejemplo:

$Tresul := \pi_{B,D}(Q)$

Q			Tresul	
B	D	E	B	D
2	1	0	2	1
1	1	1	1	1
2	1	3	0	3
0	3	0	3	0
3	0	0		



### 4.3.1 Álgebra relacional: unión

Notación:  $R \cup S$

Ejemplo:

$T1 := \pi_{B,D}(Q)$

$Tresul := T1 \cup S$

T1		S		Tresul	
B	D	B	D	B	D
2	1	0	3	2	1
1	1	3	0	1	1
0	3	2	1	0	3
3	0			3	0
				0	3
				1	1



### 4.3.1 Álgebra relacional: diferencia

Notación: **R - S**

Ejemplo:

Tresul:= R - T

R			T			Tresul		
A	B	C	A	B	C	A	B	C
1	0	1	1	1	0	1	0	0
1	0	0	1	0	1	0	3	2
0	3	2	1	2	1	0	2	0
1	2	3	2	0	0			
0	2	0	1	2	3			



### 4.3.1 Álgebra relacional: producto cartesiano

- Notación: **R x S**
- Ejemplo:
  - Tresul:=R x S
  - Grado(R)=3 Grado(S)=2
    - Grado(R x S)=Grado(R)+Grado(S)=5
  - Cardinalidad(R)=5 Cardinalidad (S)=3
    - Cardinalidad(R x S)=C(R)XC(S)=15

R			S		Tresul				
A	B	C	B	D	A	R.B	C	S.B	D
1	0	1	0	3	1	0	1	0	3
1	0	0	3	0	1	0	1	3	0
0	3	2	2	1	1	0	0	2	1
1	2	3			1	0	0	3	0
0	2	0			0	3	2	0	3
					0	3	2	3	0
					0	3	2	2	1
					...	...	...	...	...



### 4.3.1 Álgebra relacional: intersección

Notación:  $R \cap S$

Ejemplo:

Tresul:=  $R \cap T$

R			T			Tresul		
A	B	C	A	B	C	A	B	C
1	0	1	1	1	0	1	0	1
1	0	0	1	0	1	1	2	3
0	3	2	1	2	1			
1	2	3	2	0	0			
0	2	0	1	2	3			



### 4.3.1 Álgebra relacional: reunión natural (natural join)

Notación:  $R \bowtie S$

Ejemplo:

Tresul:=  $R \bowtie T$

R			S		Tresul			
A	B	C	B	D	A	B	C	D
1	0	1	0	3	1	0	1	3
1	0	0	3	0	1	0	0	3
0	3	2	2	1	0	3	2	0
1	2	3			1	2	3	1
0	2	0			0	2	0	1



### 4.3.1 Álgebra relacional: división

Notación:  $R \div S$

Ejemplo:

Tresul:=  $Q \div V$

Q			V		Tresul	
B	D	E	E		B	D
2	1	0	0		2	1
1	1	1	3			
2	1	3				
0	3	0				
3	0	0				



### 4.3.1 Álgebra relacional: ejemplos de equivalencia con

SQL

```
SELECT AL.nombre, ASIG.nombre, nota
```

```
FROM
```

```
  AL, ASIG, ALAS
```

```
WHERE
```

```
  AL.id = ALAS.id_al AND ASIG.id = ALAS.id_as
```

```
 $\pi_{AL.nombre, ASIG.nombre, nota} \left( \sigma_{AL.id=ALAS.id\_al \text{ AND } ASIG.id=ALAS.id\_as} (AL \times ASIG \times ALAS) \right)$ 
```



## 4.3.2 Objetivo

- Disminuir el tiempo de ejecución de las consultas que se realizan frecuentemente:
  - Modificar el diseño físico:
    - Añadir redundancia de datos: atributos calculables, vistas materializadas
    - Añadir/modificar índices, clusters, etc.
  - Analizar la consulta:
    - Escribiéndola de otra manera
    - Aportando más información al DBMS
    - Dando “consejos” (*hints*) al DBMS sobre qué estrategia seguir


→ Es necesario conocer cómo elabora un plan de ejecución el DBMS, analizarlo y diseñar soluciones.



## 4.3.2 Objetivo: un ejemplo

- Tablas de “proveedores” (S) y “pedidos”(P) con 100 proveedores y 10.000 pedidos.
- Sólo 50 pedidos con el artículo P2.
- Consulta: “Obtener los nombres de los proveedores que nos sirven el artículo P2”.

SELECT DISTINCT S.NOMBRE FROM S, P WHERE S.S#=P.S# AND P.A#="P2";



$\Pi_{S.nombre} (\sigma_{A\#="P2"} (\sigma_{S.S\#=P.S\#} (S \times P)))$

1.  $S \times P$

$Card(S \times P) = 100 \times 10000 = 1.000.000$

2.  $\sigma_{S.S\#=P.S\#} (S \times P)$

$Card(\sigma_{S.S\#=P.S\#} (S \times P)) = 10.000$

3.  $\sigma_{A\#="P2"} (\sigma_{S.S\#=P.S\#} (S \times P))$

$Card(\sigma_{A\#="P2"} (\sigma_{S.S\#=P.S\#} (S \times P))) = 50$

Total operaciones E/S: 3.010.000

$\Pi_{S.nombre} (\sigma_{S.S\#=P.S\#} (S \times (\sigma_{A\#="P2"} (P))))$

1.  $\sigma_{A\#="P2"} (P)$

$Card(\sigma_{A\#="P2"} (P)) = 50$  (lectura de 10.000)

2.  $S \times (\sigma_{A\#="P2"} (P))$

$Card(S \times (\sigma_{A\#="P2"} (P))) = 100 \times 50 = 5000$

3.  $\sigma_{S.S\#=P.S\#} (S \times (\sigma_{A\#="P2"} (P)))$

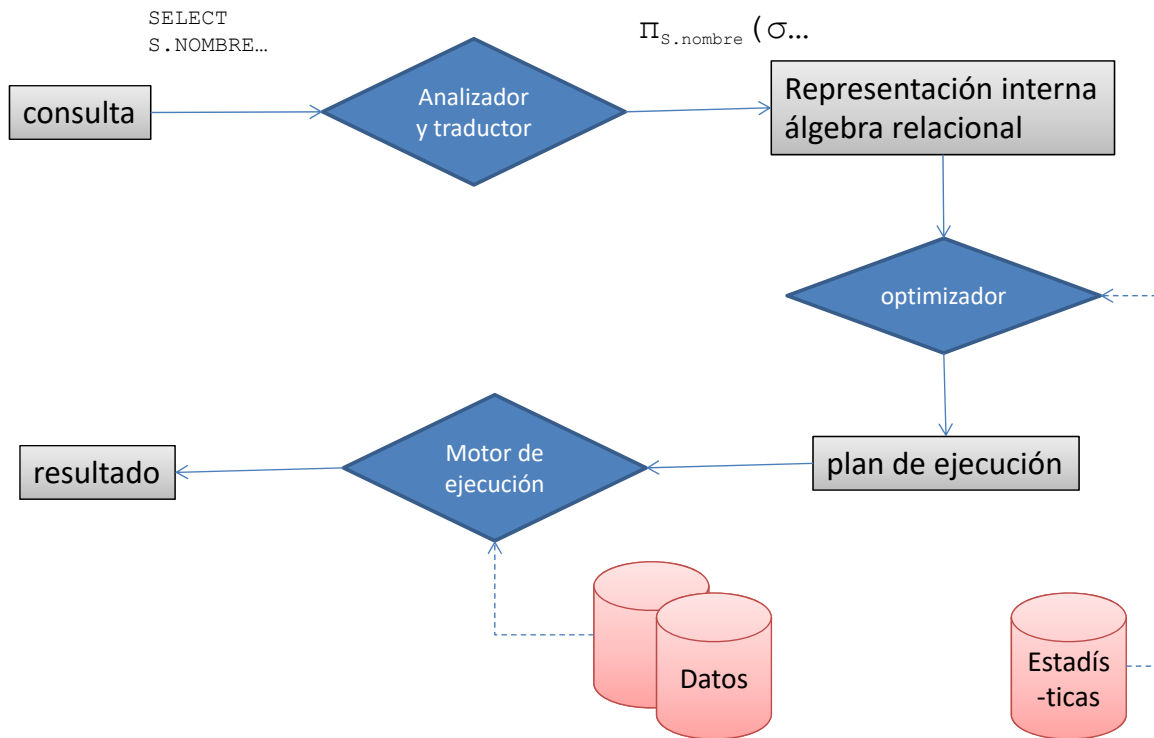
$Card(\sigma_{S.S\#=P.S\#} (S \times (\sigma_{A\#="P2"} (P)))) = 50$

Total operaciones E/S: 10.100

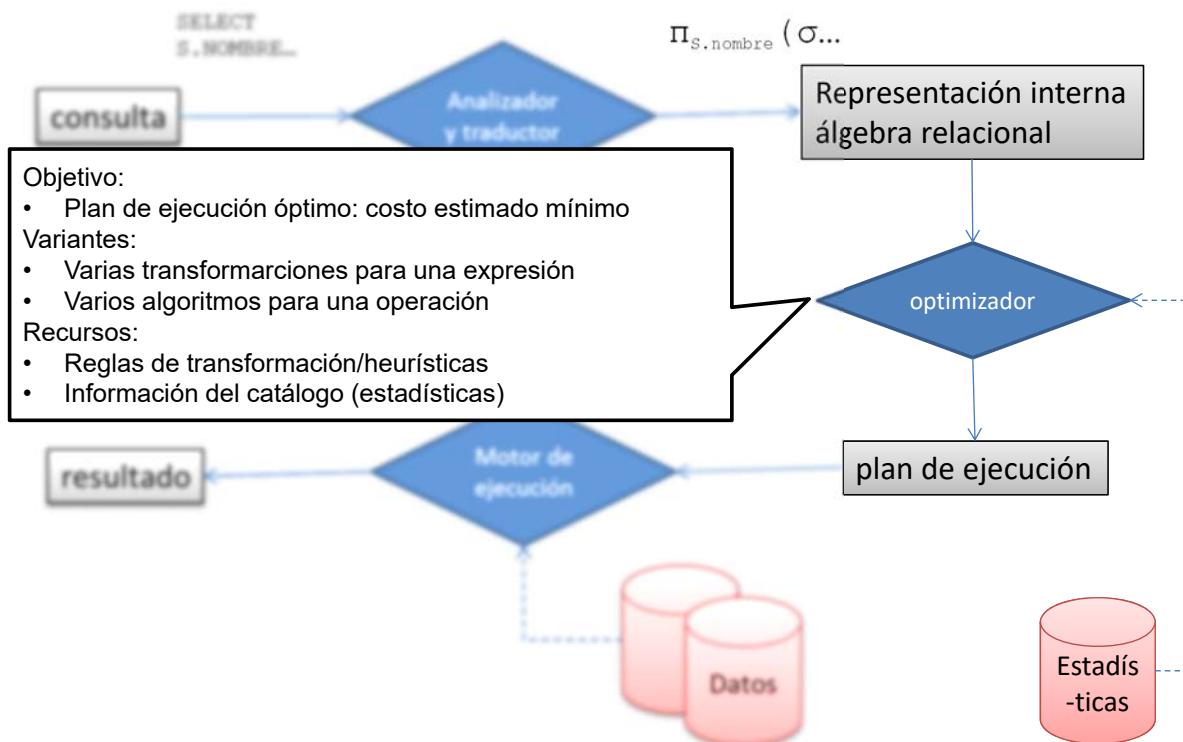




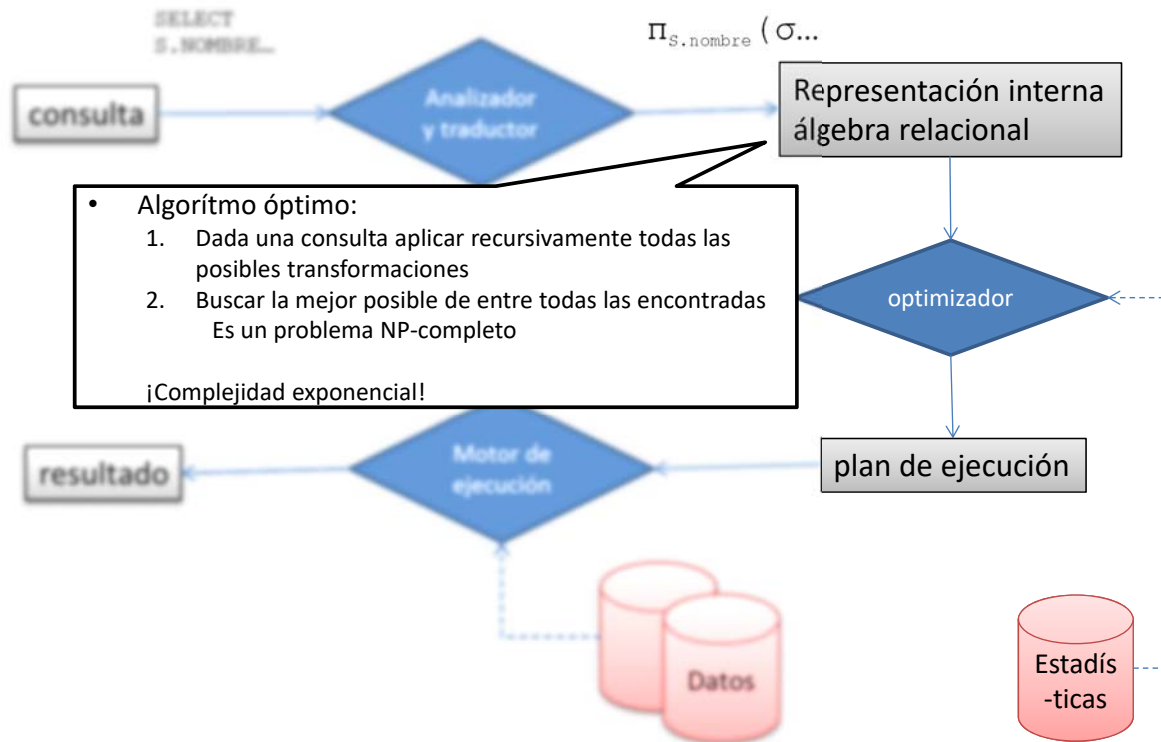
### 4.3.3 Visión general



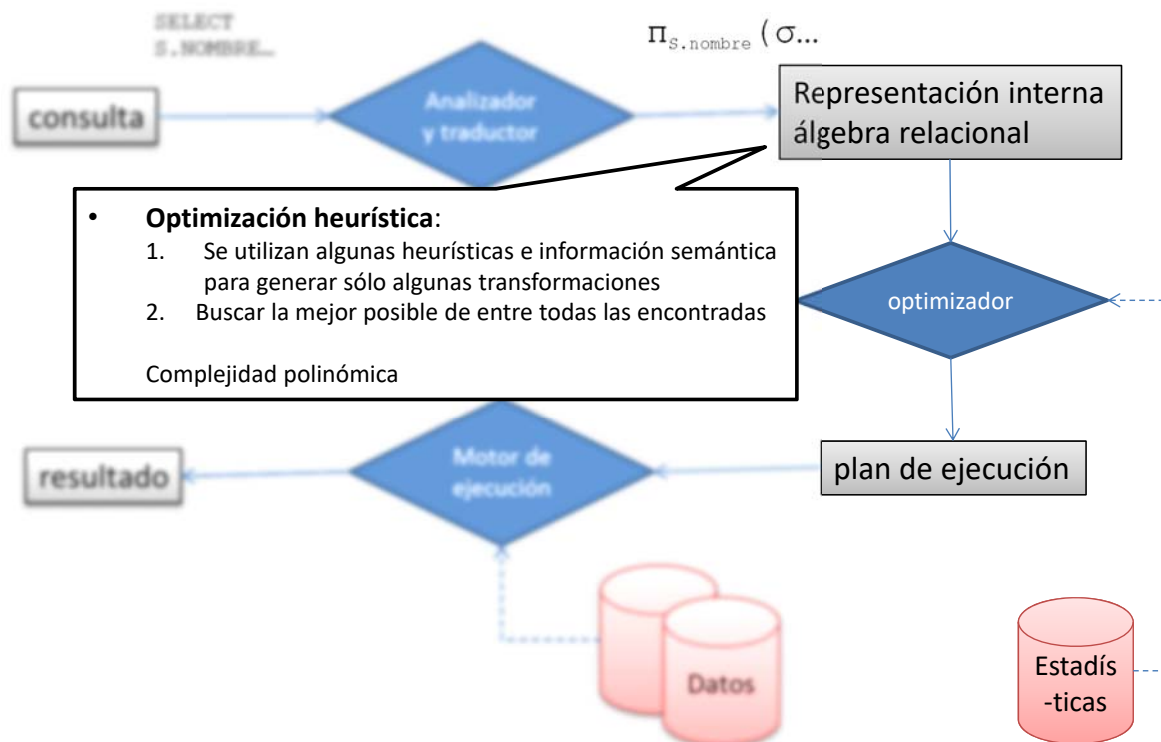
### 4.3.3 Visión general



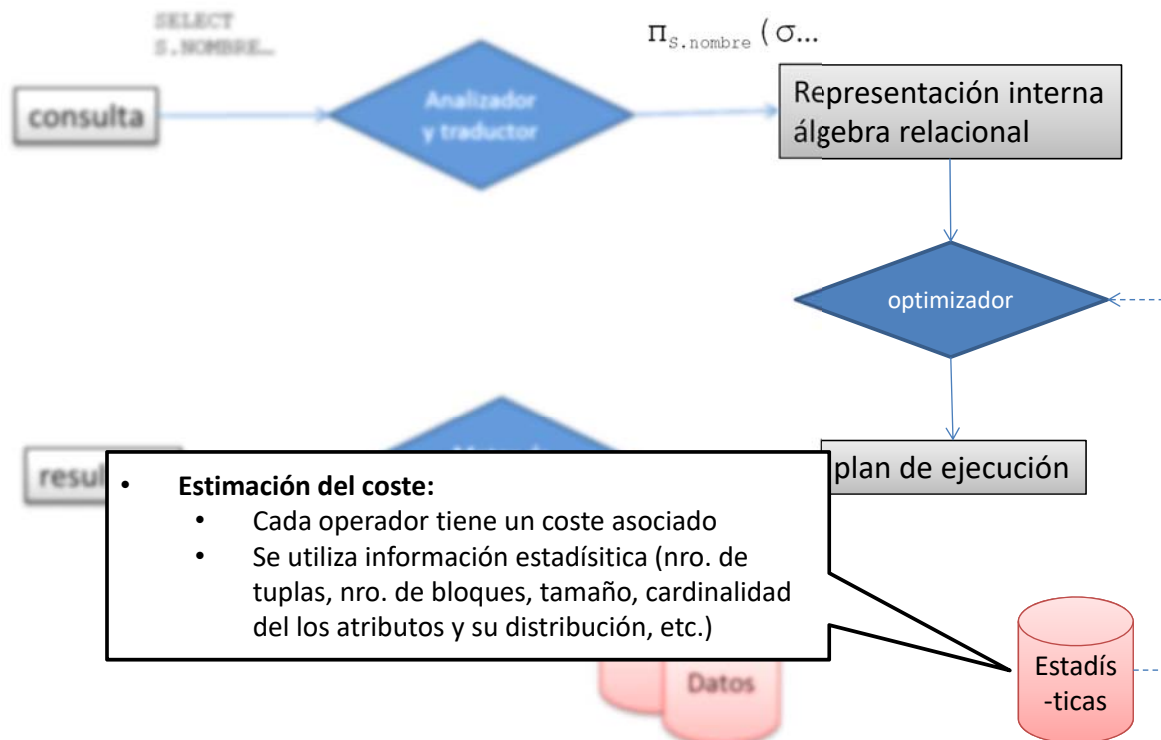
### 4.3.3 Visión general



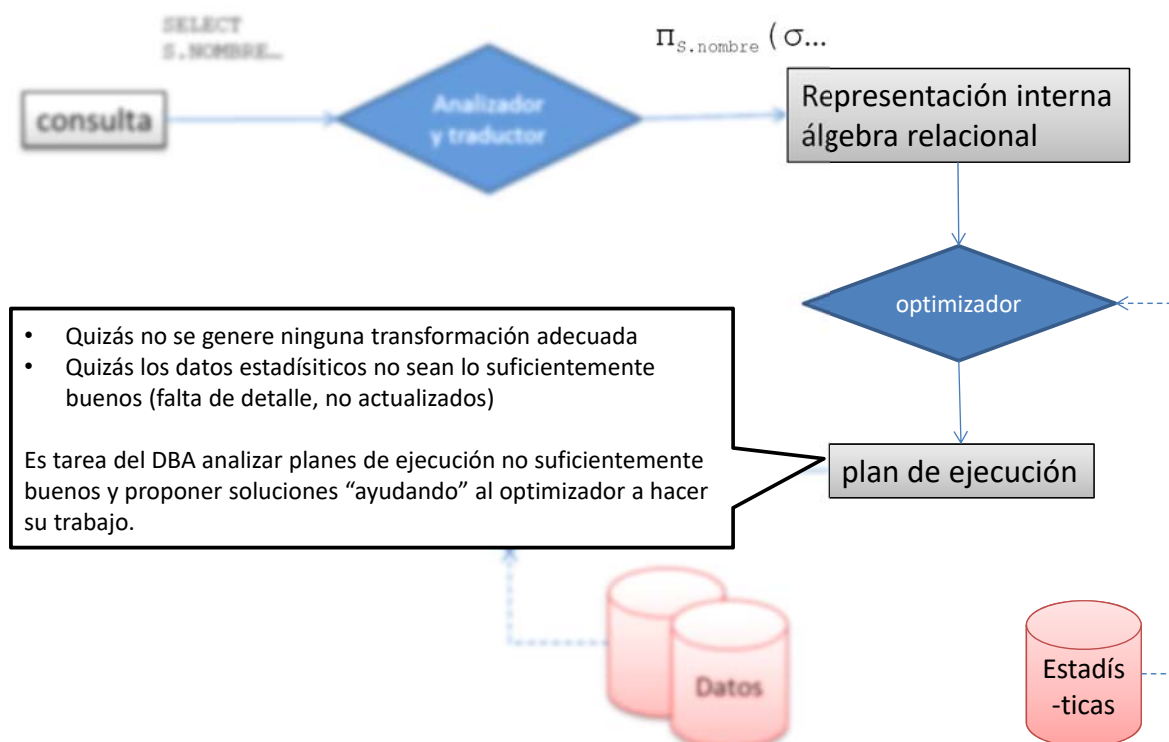
### 4.3.3 Visión general





### 4.3.3 Visión general



### 4.3.3 Visión general



## 4.3.4 Optimización heurística: reglas de equivalencia



## 4.3.4 Transformar expresión: reglas de equivalencia

### 1. Cascada de selecciones

$$\sigma_{C1 \wedge C2}(A) \equiv \sigma_{C1}(\sigma_{C2}(A))$$

### 2. Commutación de selecciones

$$\sigma_{C1}(\sigma_{C2}(A)) \equiv \sigma_{C2}(\sigma_{C1}(A))$$

### 3. Cascada de proyecciones

$$\pi_{P2}(\pi_{P1}(A)) \equiv \pi_{P2}(A)$$

### 4. Equivalencia de Reunión

$$\sigma_{C1}(A \bowtie B) \equiv A \bowtie_{C1} B$$

### 5. Commutatividad (reunión)

$$A \bowtie B \equiv B \bowtie A$$

### 6. Asociatividad (reunión)

$$(a) A \bowtie (B \bowtie C) \equiv (A \bowtie B) \bowtie C$$

$$(b) A \bowtie_{C1 \wedge C3} (B \bowtie_{C2} C) \equiv (A \bowtie_{C1} B) \bowtie_{C2 \wedge C3} C$$

donde  $C1$  sólo implica atributos de  $A$  y  $B$  y  $C2$  sólo implica atributo de  $B$  y  $C$

### 7. Propiedad distributiva (reunión)

$$(a) \sigma_{C1}(A \bowtie B) \equiv \sigma_{C1}(A) \bowtie B$$

$$(b) \sigma_{C1 \wedge C2}(A \bowtie B) \equiv \sigma_{C1}(A) \bowtie \sigma_{C2}(B)$$

si  $C1$  sólo implica atributos de  $A$  y  $C2$  sólo atributos de  $B$

### 8. Propiedad distributiva (proyección)

$$\pi_P(A \bowtie B) \equiv (\pi_{P_A}(A)) \bowtie (\pi_{P_B}(B))$$

donde  $P_A$ ,  $P_B$  son el conjunto de atributos involucrados en  $\pi_P$  y necesarios para hacer la proyección

### 9. Commutatividad (unión e intersección)

### 10. Asociatividad (unión e intersección)

### 11. Propiedad distributiva (selección, operadores conjuntos)

$$\sigma_{C1}(A - B) \equiv \sigma_{C1}(A) - \sigma_{C1}(B)$$

### 12. Propiedad distributiva (proyección y unión)

$$\pi_P(A \cup B) \equiv \pi_P(A) \cup \pi_P(B)$$



## 4.3.4 Transformar expresión: ejemplo de heurísticas

usuales

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

1. Ejecutar operaciones de restricción  $\sigma$  tan pronto como sea posible
2. Ejecutar primero las restricciones  $\sigma$  más restrictivas (las que producen menor nº de filas)
3. Combinar un producto cartesiano  $\times$  con una restricción  $\sigma$  subsiguiente cuya condición represente una condición de reunión, convirtiéndolas en un join
4. Ejecutar las operaciones de proyección  $\pi$  tan pronto como sea posible



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago

## 4.3.4 Transformar expresión: ejemplos

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

Consulta: Obtener los nombres de los suministradores que nos sirven el artículo P2

-- S: Suministradores, P: Producto

$\Pi_{S.nombre} (\sigma_{A\#="P2" \wedge S.S\#=P.S\#} (S \times P))$

Transformación:

1. regla 7a:

$\Pi_{S.nombre} (\sigma_{S.S\#=P.S\#} (S \times \sigma_{A\#="P2"} (P)))$



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago

## 4.3.4 Transformar expresión: ejemplos

### Consulta: Alumnos con más de un 7 en BBDD

-- A:alumno, B:alas,C:asig

$\Pi_{A.nombre} (\sigma_{nota>7} \wedge C.nombre='BBDD' \wedge A.dni=B.dni \wedge B.as=C.as (A \times B \times C))$

Transformación:

1. regla 7b:

$\Pi_{A.nombre} (\sigma_{B.as=C.as} \wedge A.dni=B.dni (A \times \sigma_{nota>7} (B) \times \sigma_{C.nombre='BBDD'} (C)))$

2. regla 7b:

$\Pi_{A.nombre} (\sigma_{B.as=C.as} (\sigma_{A.dni=B.dni} (A \times \sigma_{nota>7} (B)) \times \sigma_{C.nombre='BBDD'} (C)))$

3. regla 4 (reescritura):

$\Pi_{A.nombre} ((A \otimes \sigma_{nota>7} (B)) \otimes \sigma_{C.nombre='BBDD'} (C))$

4. regla 8

$\Pi_{A.nombre} ((\Pi_{nombre,dni} (A) \otimes \sigma_{nota>7} (B)) \otimes \sigma_{C.nombre='BBDD'} (\Pi_{nombre,as} (C)))$



## 4.3.5 Estimación de coste

- El Optimizador tiene un conjunto de técnicas para realizar cada operación
- Ejemplo: técnicas para implementar la operación de selección  $\sigma$ :
  - Búsqueda Lineal
  - Búsqueda Binaria
  - Empleo de Índice Primario
  - Empleo de Índice Secundario
- ¿Cómo elige el Optimizador las técnicas adecuadas en cada caso?



## 4.3.5 Estimación de coste

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

- Variable a minimizar: tiempo total de ejecución.
- Factores que intervienen:
  1. Acceso a memoria secundaria
  2. Almacenamiento en disco de estructuras temporales
  3. Uso de CPU
  4. Acceso a los buffers en memoria principal
  5. Coste de comunicación por red
- Estos factores se de estiman atendiendo a diversos estadísticos. Por ejemplo, para una relación dada:
  - Número de tuplas, **r**.
  - Tamaño medio de cada tupla, **R**.
  - Número de bloques necesarios para almacenar la relación, **b**.
  - Factor de bloqueo (cuántas tuplas caben en un bloque), **bfr**.
  - Organización primaria de la tabla: ordenada/desordenada, índice primario, pertenencia a un cluster, organizada por índice, particionada...
  - Nro. de valores distintos de un atributo, **d**.
  - Distribución media de valores de tal atributo, **sl**
  - Cardinalidad de selección(nro. de tuplas que tienen un valor determinado), **s = sl\*r**
  - Altura del índice para cada atributo, **x**
  - ....



## 4.3.5 Estimación de coste

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

- Variable a minimizar: tiempo total de ejecución.
- Factores que intervienen:
  1. Acceso a memoria secundaria
  2. Almacenamiento en disco de estructuras temporales
  3. Uso de CPU
  4. Acceso a los buffers en memoria principal
  5. Coste de comunicación por red
- Estos factores se de estiman atendiendo a diversos estadísticos. Por ejemplo, para una relación dada:
  - Número de tuplas, **r**.
  - Tamaño medio de cada tupla, **R**.
  - Número de bloques necesarios para almacenar la relación, **b**.
  - Factor de bloqueo (cuántas tuplas caben en un bloque), **bfr**.
  - Organización primaria de la tabla: ordenada/desordenada, índice primario, pertenencia a un cluster, organizada por índice, particionada...
  - Nro. de valores distintos de un atributo, **d**.
  - Distribución media de valores de tal atributo, **sl**
  - Cardinalidad de selección(nro. de tuplas que tienen un valor determinado), **s = sl\*r**
  - Altura del índice para cada atributo, **x**
  - ....

¿Se podrá mantener información como esta siempre actualizada?



## 4.3.5 Estimación de coste

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

- Variable a minimizar: tiempo total de ejecución.
- Factores que intervienen:
  - Acceso a memoria secundaria
  - Almacenamiento en disco de estructuras temporales
  - Uso de CPU
  - Acceso a los buffers en memoria principal
  - Coste de comunicación por red
- Estos factores se estiman atendiendo a diversos estadísticos. Por ejemplo, para una relación dada:
  - Número de tuplas,  $r$ .
  - Tamaño medio de cada tupla,  $R$ .
  - Número de bloques necesarios para almacenar la relación,  $b$ .
  - Factor de bloqueo (cuántas tuplas caben en un bloque),  $f$ .
  - Organización primaria de la tabla: ordenada/desordenada, ordenada por índice primario, pertenencia a un cluster, organizada por índice, particionada...
  - Nro. de valores distintos de un atributo,  $d$ .
  - Distribución media de valores de tal atributo,  $sl$
  - Cardinalidad de selección (nro. de tuplas que tienen un valor determinado),  $s = sl \cdot r$
  - Altura del índice para cada atributo,  $x$
  - ....

En un atributo clave  
¿qué valores tendrá  
en  $d, sl$  y  $s$ ?



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago

## 4.3.5 Estimación de coste: selección

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

Algoritmo	Descripción	Coste (en accesos a bloques)
S1	Se cargan secuencialmente todos los bloques	$b$ $b/2$ , si se trata de una clave
S2	Búsqueda binaria sobre un campo ordenado	$\log_2 b$ , si se trata de una clave $\log_2 b + (s/bfr) - 1$ , en otro caso
S3a	Usando un índice primario para recuperar una única tupla	$x + 1$
S3b	Usando un índice hash para recuperar una única tupla	1 o 2, depende del tipo de hash implementando
S4	Usando un índice ordenado para recuperar varias tuplas	$x + (b/2)$
S5	Usando un <i>cluster</i> para recuperar varias tuplas	$x + (s/bfr)$
S6	Usando un índice secundario	(a) $x + 1 + s$ (b) $x + (b_{it}/2) + (r/2)$

Selecciones que involucran más de un atributo:

S7: Selección conjuntiva. Se recuperan las filas por uno de los campos y se filtran iterativamente atendiendo al resto de las condiciones. El coste: la del campo por el que se recuperó

S8: Selección conjuntiva usando un índice compuesto: la misma que S3a, S5 o S6



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago



## 4.3.5 Estimación de coste: Ejemplo

- **Tabla Empleado**

- $r_E = 10.000$  filas
- $b_E = 2000$  bloques
- $bfr_E = 10000 \text{ filas} / 2000 \text{ bloques} = 5 \text{ filas/bloque}$

- **Diseño físico de la tabla:**

1. Un índice cluster en el campo **salario**
  - $X_{\text{salario}} = 3$  accesos
  - $S_{\text{salario}} = 20$  filas ( $sl_{\text{salario}} = 0.002$ )
2. Un índice secundario en el atributo clave **dni**
  - $X_{\text{dni}} = 4$  accesos
  - $S_{\text{dni}} = 1$  ( $sl_{\text{dni}} = 0.0001$ , es un campo clave)
3. Un índice secundario en un campo no clave **dpto**
  - $X_{\text{dpto}} = 2$  accesos
  - $d_{\text{dpto}} = 125$  departamentos
  - $sl_{\text{dpto}} = 1/125 = 0.008$
  - $S_{\text{dpto}} = r_E * sl_{\text{dpto}} = 80$
4. Un índice secundario en el campo **sexo**
  - $X_{\text{sexo}} = 1$
  - $d_{\text{sexo}} = 2$
  - $S_{\text{sexo}} = r_E / d_{\text{sexo}} = 10000 / 2 = 5000$



## 4.3.5 Estimación de coste: Ejemplo

- **Ej1:  $\sigma_{\text{dni}='72123456H'}(\text{EMPLEADO})$**

- $C_{S1}(\text{Ej1}) = b/2 = 1000$
- $C_{S6a}(\text{Ej1}) = x_{\text{dni}} + s_{\text{dni}} = 4 + 1 = 5$  ✓

- **Ej2:  $\sigma_{\text{dpto}>5}(\text{EMPLEADO})$**

- $C_{S1}(\text{Ej2}) = b = 2000$  ✓
- $C_{S6b}(\text{Ej2}) = x_{\text{dpto}} + (b_{11}/2) + (r/2) = 2 + 4/2 + 10000/2 = 5004$

- **Ej3:  $\sigma_{\text{dpto}=5}(\text{EMPLEADO})$**

- $C_{S1}(\text{Ej3}) = b = 2000$
- $C_{S6a}(\text{Ej3}) = x_{\text{dpto}} + s_{\text{dpto}} = 2 + 80 = 82$  ✓

- **Ej4:  $\sigma_{\text{dpto}=5 \wedge \text{salario}>30000 \wedge \text{sexo}='F'}(\text{EMPLEADO})$**

Selección conjuntiva. Calculamos el coste para cada condición

- $\text{dpto}=5 \rightarrow C_{S1}(\text{Ej4}) = 82$  ✓
- $\text{salario}>30000 \rightarrow$   
 $C_{S4}(\text{Ej4}) = X_{\text{salario}} + (b_E/2) = 3 + (2000/2) = 10003$
- $\text{Sexo}='F' \rightarrow C_{S6a}(\text{Ej3}) = x_{\text{sexo}} + s_{\text{sexo}} = 1 + 5000 = 5001$



## 4.3.5 Estimación de coste: reunión

- Es necesario estimar el número de tuplas resultante: especificidad de reunión (*join selectivity*):

$$j_s = | (R \otimes_C S) | / | R \times S | = | (R \otimes_C S) | / (| R | * | S |)$$

donde R y S son dos relaciones y C la condición del *join*

- En el peor caso  $j_s=1$ , coincide con un producto cartesiano
- Tamaño del *join*:  $j_s * | R | * | S |$
- Para estimar el coste de la reunión debemos considerar:
  - El coste de lectura, que variará según los accesos físicos disponibles
  - +
  - El coste de escribir el resultado en disco:
    - $(j_s * | R | * | S |) / bfr_{RS}$

donde  $bfr_{RS}$  es el número de filas que caben en cada bloque



## 4.3.5 Estimación de coste: reunión natural

Algoritmo	Descripción	Coste (en accesos a bloques)
J1	Fuerza bruta: bucle anidado que recorre ambas tablas, a modo de matriz bidimensional	$C_{J1} = b_R + (b_R * b_S) + ((j_s *   R   *   S  ) / bfr_{RS})$
J2	Si existe un índice en una de las tablas sobre los campos del <i>join</i> , se recorre secuencialmente la tabla no indexada y se usa el índice para recuperar los valores coincidentes en la tabla indexada	Índice secundario: $C_{J2a} = b_R + (  R   * (x_B + s_B)) + ((j_s *   R   *   S  ) / bfr_{RS});$ Índice de tipo cluster: $C_{J2b} = b_R + (  R   * (x_B + (s_B / bfr_B))) + ((j_s *   R   *   S  ) / bfr_{RS});$ Índice primario: $C_{J2c} = b_R + (  R   * (x_B + 1)) + ((j_s *   R   *   S  ) / bfr_{RS});$ Índice hash: $C_{J2d} = b_R + (  R   * h) + ((j_s *   R   *   S  ) / bfr_{RS});$ $h=1$ o $h=2$ , según tipo de tabla <i>hash</i>
J3	Si ambas tablas están físicamente ordenadas por los campos del <i>join</i> , se recorren secuencialmente y a la vez ambas tablas recuperando los valores coincidentes	$C_{J3a} = C_S + b_R + b_S + ((j_s *   R   *   S  ) / bfr_{RS})$ $C_S$ = Coste de ordenar ambas tablas



### 4.3.5 Estimación de coste: ejemplo

- $\Join$  EMPLEADO  $\otimes_{\text{dno=Dnumber}}$  DPTO ?
  - Dnumber clave de departamento,  $x_{\text{Dnumber}}=1$
  - $r_D = 125$  (hay 125 departamentos)
  - $b_D = 13$  bloques
  - $\text{bfr}_{ED}=4$
- J1, EMPLEADO  $\otimes_{\text{dno=Dnumber}}$  DPTO
$$C_{J1} = b_E + (b_E * b_D) + ((js * r_E * r_D) / \text{bfr}_{ED})$$
$$= 2000 + (2000 * 13) + (((1/125) * 10.000 * 125) / 4) = 30.500$$
- J1, DPTO  $\otimes_{\text{dno=Dnumber}}$  EMPLEADO
$$C_{J1} = b_D + (b_D * b_E) + ((js * r_E * r_D) / \text{bfr}_{ED})$$
$$= 13 + (13 * 2000) + (((1/125) * 10.000 * 125) / 4) = 28513$$
- J2, EMPLEADO  $\otimes_{\text{dno=Dnumber}}$  DPTO
$$C_{J2} = b_E + (r_E * (x_{\text{Dnumber}} + 1)) + ((js * r_E * r_D) / \text{bfr}_{ED})$$
$$= 2000 + (10000 * 2) + (((1/125) * 10.000 * 125) / 4) = 24500$$
- J2, DPTO  $\otimes_{\text{dno=Dnumber}}$  EMPLEADO
$$C_{J2} = b_D + (r_D * (x_{\text{Dno}} + S_{\text{Dno}})) + ((js * r_E * r_D) / \text{bfr}_{ED})$$
$$= 13 + (125 * (2 + 80)) + (((1/125) * 10.000 * 125) / 4) = 12763 \checkmark$$



### 4.3.5 Estimación de coste: algunas anotaciones

- Una consulta con n reuniones tendrá n! posibles ordenes. No siempre es posible evaluarlas todas
- El valor de js en ocasiones está mal estimado
- La **optimización semántica** puede utilizar restricciones del dominio codificadas en la base de datos:
  - Algunas se usan: restricción de identidad, integridad referencial, etc.
  - Otras, son más propias de ontologías y bases de conocimiento:
    - Un alumno no tiene más de siete convocatorias → no buscar más convocatorias una vez encontradas siete
    - Una asignatura pertenece exclusivamente a uno de los siguiente conjuntos: obligatoria, optativa, troncal → dejar de buscar una vez localizada en uno de esos conjuntos.



## 4.3.6 Optimización de consultas en Oracle:

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

- Utiliza transformaciones sobre la consulta y estimación del coste
- A cada plan le asigna un coste estimado:
  - E/S, tiempo de CPU, uso de memoria
  - Hipótesis: menor coste → menor tiempo de ejecución
  - Realidad: no siempre es así
- Permite incluir consejos o directrices sobre cómo realizar el plan de ejecución
  - Priorizar la obtención de primeros resultados o la resolución completa de la consulta
  - Qué acceso a dato utilizar (secuencial índice, etc)
  - En qué orden ejecutar los joins
  - Cómo evaluar las condiciones de tales joins
  - ...



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago

## 4.3.6 Optimización de consultas en Oracle: ejemplo (1)

Tema 4: Optimización de Bases de datos

Parte III: Optimización de consultas

### • Consulta:

```
SELECT DISTINCT A.NODO_ID, B.NODO_B_ID NODO_EQ1
FROM A, B, C
WHERE A.NODO_ID = B.NODO_A_ID
AND B.NODO_B_ID = C.NODO_ID;
```

SQL> @c:\oracle\ora92\rdbms\admin\utlxpls

PLAN\_TABLE\_OUTPUT

Id	Operation	Name	Rows	Bytes	Cost
0	SELECT STATEMENT		5554	124K	<b>23</b>
1	SORT UNIQUE		5554	124K	23
2	NESTED LOOPS		5554	124K	2
<b>3</b>	<b>MERGE JOIN CARTESIAN</b>		<b>5985M</b>	<b>61G</b>	<b>2</b>
4	TABLE ACCESS FULL	TMPNOD	1327	6635	2
5	BUFFER SORT		4510K	25M	
6	INDEX FULL SCAN	PK_NOD	4510K	25M	
* 7	INDEX RANGE SCAN	IDX_NOD	1	12	

Predicate Information (identified by operation id):

7 - access("B"."NODO\_B\_ID"="C"."NODO\_ID" AND "A"."NODO\_ID"="B"."NODO\_A\_ID")

Tiempo de ejecución: 11 horas



Grado en Informática

Gestión y Administración de Bases de Datos

Fernando Martínez Santiago

## 4.3.6 Optimización de consultas en Oracle: ejemplo (y 2)

- Consulta (reescrita):

```
SELECT DISTINCT A.NODO_ID, B.NODO_B_ID NODO_EQ1
FROM A, (select distinct nodo_a_id, nodo_b_id from B) B, C
WHERE A.NODO_ID = B.NODO_A_ID
AND B.NODO_B_ID = C.NODO_ID;
```

### PLAN\_TABLE\_OUTPUT

Id	Operation	Name	Rows	Bytes	Cost
0	SELECT STATEMENT		5554	200K	<b>13626</b>
1	NESTED LOOPS		5554	200K	13626
2	NESTED LOOPS		5554	168K	13626
3	VIEW		7159K	177M	13626
4	SORT UNIQUE		7159K	81M	13626
5	TABLE ACCESS FULL	RE_03	7159K	81M	2589
* 6	INDEX UNIQUE SCAN	PK_EL_3	1	5	
* 7	INDEX UNIQUE SCAN	PK_R_3	1	6	

Predicate Information (identified by operation id):

6 - access("B"."NODO\_B\_ID"="C"."NODO\_ID")

7 - access("A"."NODO\_ID"="B"."NODO\_A\_ID")

Tiempo de ejecución: 1 hora 20 segundos



## 4.3.7 Ejercicios

1. ¿Por qué se debe expresar la consulta SQL en términos de álgebra relacional?
2. Si tuvieras que implementar un join, ¿cuándo usarías  $\Join_1$  y cuándo  $\Join_2$ ?
3. ¿Qué es la optimización heurística? ¿es óptima?
4. ¿Por qué no es posible implementar la optimización semántica completa en las DBMS actuales? ¿qué haría falta?
5. Dada la siguiente consulta

```
SELECT E.Fname, E.Lname, E.Address
FROM EMPLEADO E, DEPARTAMENTO D
WHERE D.Dname='Research' AND D.Dnumber=E.Dno;
```

1. Expresa la consulta usando álgebra relacional
2. Dibuja un árbol de equiencia
3. Transforma el árbol aplicando las heurísticas del apartado 4.3.4



## 4.3.7 Ejercicios

6. Usando los datos estadísticos del ejemplo de estimación de coste del apartado 4.3.5, ¿qué coste podrían tener la siguiente expresiones usando los diferentes algoritmos propuestos?

$\sigma_{\text{salario} > 30000} (\text{EMPLEADO} \otimes_{\text{Dno=Dnumber}} \text{DEPARTAMENTO})$

